Лабораторная работа № 3

Эволюционный синтез архитектуры малого классификатора. Вариант 10, трек B.

Холодков Антон Евгеньевич
Группа 517 · N = 28 · Q = 1 · Y = 26 · V = 10
5 ноября 2026 года

1. Постановка задачи и вариант

Вариант V = 1 + ((17×28 + 7×1 + 26) mod 20) = 10. Выбран трек B: настройка архитектуры малого классификатора. В методичке не задана формула распределения между треками A/B; выбор трека B следует подтвердить при защите, если преподаватель назначает трек отдельно.

Цель: эволюционно подобрать структуру бинарного классификатора, сохраняя компромисс между качеством и сложностью. Архитектура, а не только маска признаков, является объектом поиска: допускается линейная модель либо один скрытый слой различной ширины и нелинейности.

2. Данные и разделение

Синтетический набор: 480 объектов, четыре признака x из N(0,1), seed = 1051728. Метка $y = I[x1^2 + x2^2 + 0.35x3 + \varepsilon > 1.45]$, $\varepsilon \sim N(0,0.12)$. Четвёртый признак шумовой. Случайное фиксированное разбиение: train 280, validation 100, test 100. Исходные значения, метки и принадлежность к части сохранены в data.csv.

Средние и стандартные отклонения вычислены только на train. Веса обучаются только на train; fitness, ранжирование, архив и выбор трёх представителей используют только validation. Список выбранных решений сохранён в selection_before_test.json до раскрытия test. Тестовые метрики затем рассчитываются для зафиксированных решений и победителей запусков; они не меняют результат поиска.

3. Формальная модель и представление

Генотип g = (m,h,a), где $m \in \{1,\ldots,15\}$ - непустая четырёхбитная маска, $h \in \{0,2,4,8,12\}$ - число скрытых нейронов, $a \in \{\tanh,\mathrm{ReLU}\}$. При h=0 активация канонизируется и модель является логистической регрессией. Фенотип - обученная сеть, выбранные признаки и фиксированный scaler.

Для k выбранных признаков число параметров P = k+1 при h=0 и P=(k+1)h+h+1 при h>0. Вероятность класса 1 равна $\mathrm{sigmoid}(w \cdot z + b)$ либо $\mathrm{sigmoid}(v \cdot a(Wz+b)+c)$. Итого $15\times(1+4\times2)=135$ синтаксически различных архитектур.

Минимизируется $F\lambda(g)=BCEvalidation(g)+\lambda P(g)$, $BCE = \mathrm{mean}(\log(1+\exp(\mathrm{logit}))-y \cdot \mathrm{logit})$. Сравниваются $\lambda=0$ и $\lambda=0.004$. Поиск не использует test. Ограничения: непустая маска, допустимая ширина и активация, один скрытый слой; операторы сохраняют синтаксическую корректность.

4. Алгоритм и новые механизмы

Начальная популяция состоит из 24 случайных генотипов. Родители выбираются турниром из трёх. Равномерный кроссовер смешивает биты маски и структурные гены. Биты мутируют с вероятностью 0.12 каждый, ширина с вероятностью 0.35, активация с вероятностью 0.15. Пустая маска восстанавливается одним случайным признаком. Элита - одна лучшая особь; остальные места заполняются потомками.

Новый механизм - эволюция структуры сети и внешний недоминируемый архив по (BCEvalidation,P). A доминирует B, когда не хуже по обеим координатам и строго лучше хотя бы по одной. Архив позволяет интерпретировать компромиссы независимо от выбранного λ.

Внутреннее обучение реализовано собственным полным градиентным спуском: 280 шагов, learning rate 0.12, L2=0.0001. Инициализация зависит от seed запуска и генотипа, поэтому оценка повторного генотипа в том же запуске детерминирована. Повторения кэшируются отдельно для каждого запуска и конфигурации.

Условия сравнения: seeds 100–119, по 20 независимых запусков для каждого λ; ровно 240 обращений к fitness, включая начальную популяцию и попадания в кэш. Последнее поколение может быть неполным. Меняется только λ. Число фактических обучений и градиентных шагов отдельно записано в runs.csv: равенство числа обращений не означает равенства wall time и обучений. Это ограничение вычислительного сравнения.



5. Статистика серии: ошибка validation

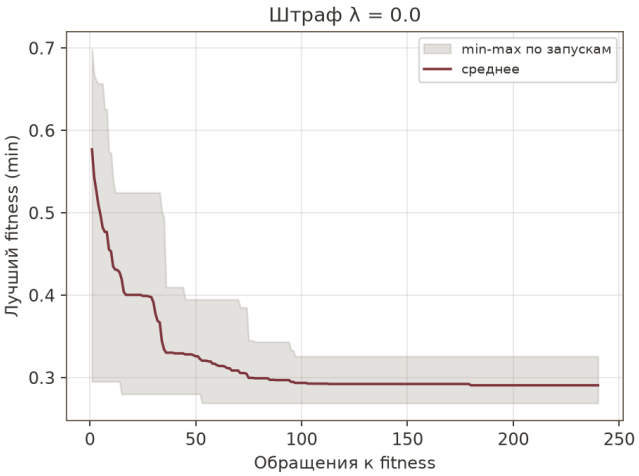
BCE следует минимизировать. В таблице приведены минимум, среднее, медиана, выборочное стандартное отклонение (ddof=1) и максимум ошибок победителей запусков. Fitness двух штрафов нельзя непосредственно сравнивать, поэтому основное сравнение качества использует исходную BCE.

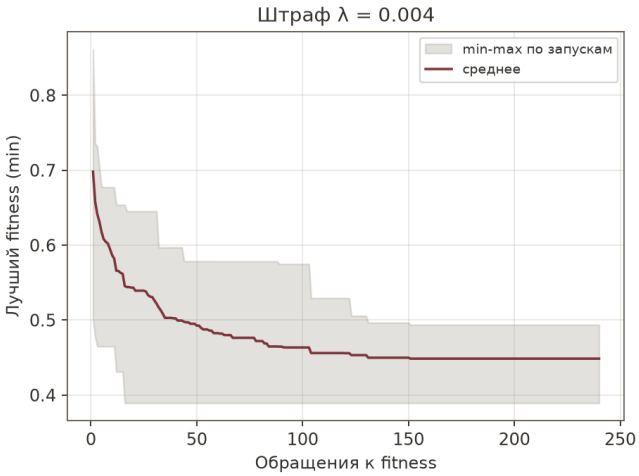
λ	Лучшее	Среднее	Медиана	s	Худшее
0.0	0.26911	0.29072	0.28900	0.01387	0.32572
0.004	0.27235	0.33582	0.32777	0.04036	0.40547

6. Затраты и устойчивость

λ=0: среднее число параметров 52.80, distinct trainings 83.55, время 0.604 с (s=0.038). λ=0.004: параметры 28.20, distinct trainings 82.60, время 0.583 с (s=0.053). Все решения синтаксически допустимы; доля допустимых = 1.

Истории содержат incumbent после каждого обращения к fitness. Средняя траектория и диапазон min-max отражают разброс между запусками, а не доверительный интервал. Независимы seed поиска/инициализации весов; набор данных фиксирован. Поэтому выводы характеризуют устойчивость на одном наборе, а не статистическую генеральную совокупность задач.





7. Три решения и компромиссы

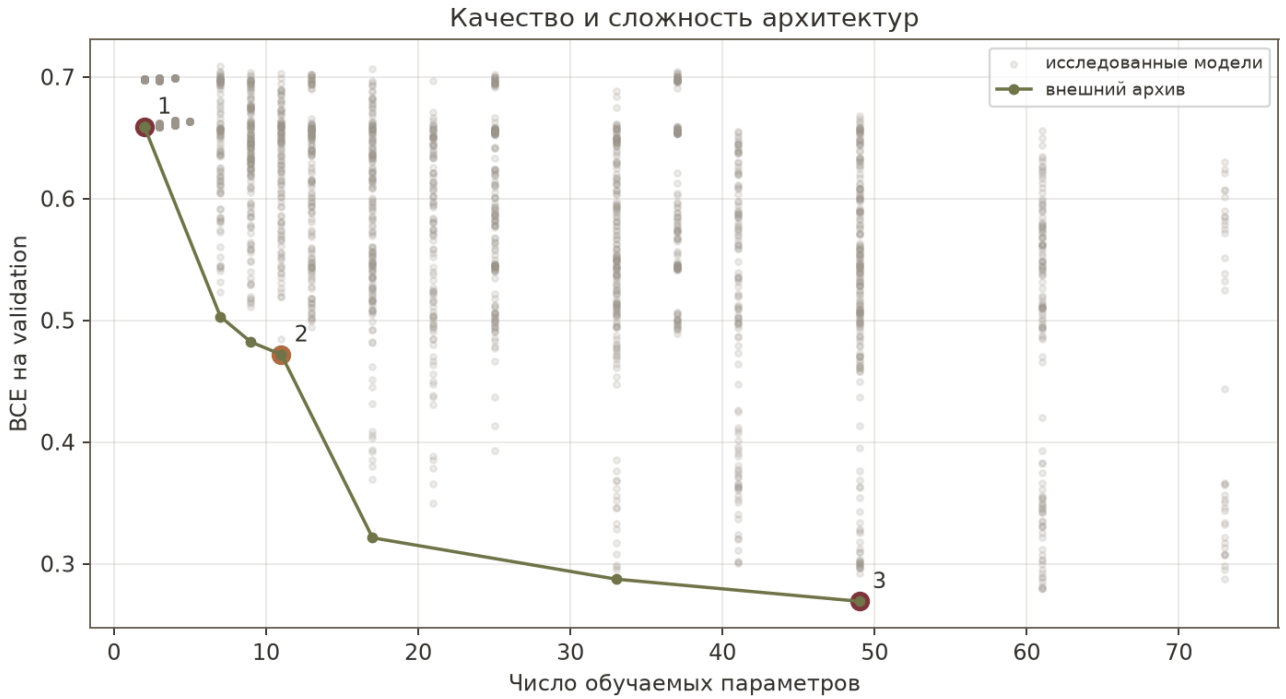
Объединённый архив содержит 18 недоминируемых моделей. Представители выбираются без test: минимальная сложность, медианная сложность архива, минимальная BCEvalidation. Таблица: признаки нумеруются с 1; h=0 означает линейную модель. Все три модели сохранены в model_1.npz–model_3.npz вместе со scaler и генотипом.

№	Признаки	h	a	P	BCEval	BCEtest	Acc test
1	[3]	0	linear	2	0.65909	0.66917	0.54000
2	[1, 2, 3]	2	relu	11	0.47190	0.52311	0.73000
3	[1, 2]	12	relu	49	0.26911	0.27786	0.92000

8. Предметный смысл фронта

Компактная модель использует 2 параметров; её ошибка validation 0.6591 и test accuracy 54.00%. Минимум validation достигается моделью с 49 параметрами: BCEvalidation 0.2691, test accuracy 92.00%. Она лучше описывает нелинейную границу, но требует больше памяти и операций.

Компромиссное решение соответствует промежуточной сложности. Линейная модель не выражает квадратичную границу, тогда как скрытые нелинейные нейроны могут её аппроксимировать. Меньшая validation-ошибка не гарантирует лучшую test-ошибку каждого отдельного представителя: это ожидаемое ограничение конечной выборки.



9. Базовые модели

Константный прогноз использует долю положительного класса в train. Логистическая регрессия на всех четырёх признаках обучается тем же собственным алгоритмом и числом шагов. Базовые модели предназначены для оценки качества, их стоимость обучения не приравнивается бюджету эволюционного поиска.

Модель	P	BCE test	Accuracy test
Константа по доле класса train	1	0.69683	0.50000
Логистическая регрессия, все признаки	5	0.69383	0.52000

10. Выводы и ограничения

Увеличение штрафа с 0 до 0.004 изменило среднюю сложность с 52.80 до 28.20 параметров и среднюю BCEvalidation с 0.29072 до 0.33582. Это наблюдаемый обмен качества на компактность, а не доказательство превосходства одной настройки для всех приложений.

Лучший по validation представитель имеет test accuracy 92.00%; линейный baseline - 52.00%. Результат оценивается по отложенному качеству и цене структуры. Для учебной демонстрации синтеза архитектуры это содержательный результат; гарантии глобального оптимума и прикладного качества отсутствуют.

Пространство из 135 архитектур достаточно мало для полного перебора: эволюция здесь изучается как метод, а не доказывается экономически необходимой. Внешний архив объединяет 40 запусков, поэтому его лучшие validation-значения подвержены множественному выбору. Один train/validation/test split и 100 тестовых объектов

ограничивают точность обобщения. Улучшения: несколько независимых наборов данных, вложенная кросс-валидация, больше повторов обучения весов, бюджет в градиентных шагах и расширение пространства архитектур.

11. Проверка и вопросы к защите

test_lab3.py проверяет допустимость операторов, формулу числа параметров, воспроизводимость обучения и поиска, точный бюджет, train-only scaler и алгоритм недоминирования. Проверки запускаются командой python -m unittest -v test_lab3.py.

Почему fitness не равен accuracy? BCE различает уверенность вероятностных прогнозов и пригодна для градиентного обучения; штраф отражает цену сложности. Почему test не входит в fitness? Иначе результат нельзя считать независимой оценкой обобщения. Почему кэш допустим? Повторный генотип имеет те же данные, инициализацию и число шагов в одном запуске; бюджет обращений и фактических обучений разделён. Где нет математической гарантии? Поиск не гарантирует глобальный минимум; качество на новых данных является экспериментальной оценкой.

12. Источник задания

Душкин Р. В. Дисциплина «Эволюционное программирование и генетические алгоритмы». Комплекс лабораторных работ, с. 12–17: ЛР3, трек B, вариант 10. Внешние наборы данных и готовые реализации оптимизаторов не использованы. NumPy используется для линейной алгебры, Matplotlib - только для графиков.

Источник задания и состав комплекта

Душкин Р. В. Дисциплина «Эволюционное программирование и генетические алгоритмы». Комплекс лабораторных работ. Методические материалы, предоставленные пользователем, 24 страницы. Индивидуальный вариант вычислен по формуле раздела 1.5. Исходный код, конфигурации, входные данные и необработанные результаты находятся в папке соответствующей работы.